

Paola Camila Dias de Moraes

<https://github.com/acamiladias/sri>

TADS São José-SC

1- Descrição do texto utilizado.

O texto utilizado pertence ao <https://huggingface.co/datasets/iara-project/news-articles-ptbr-dataset/viewer/default/train> que são noticiários.

```
documentos.csv
Arquivo  Editar  Exibir

id;documento
1;"Na tarde de domingo (17), Luva de Pedreiro abriu uma live e sugeriu que o melhor seria pagar pensão à atual namorada, Távila Gomes, grávida do primeiro filho dele. ""Sou inamovável"", disse ele, deixando seus seguidores perplexos com um suposto fim precoce do romance.Porém, mais tarde, Távila desmentiu que ambos tenham encerrado o vínculo. Em outra live, ambos ironizaram perguntas sobre o suposto fim do relacionamento. Conforme Luva, as frases horas antes teriam sido ""resenha"", ou seja, brincadeira. ""Não pode falar mais nada. Tudo o que eu faço, eu estou errado.""Em agosto, Iran Ferreira anunciou que será pai."
2;"O diretor-geral da OMS (Organização Mundial da Saúde) cobrou de Pequim mais informações sobre a origem da Covid-19 e disse que a entidade está pronta para enviar uma segunda equipe ao país para investigar o surgimento do Sars-Cov-2, já que a origem da pandemia ainda não está clara quase quatro anos após os primeiros casos surgirem na cidade chinesa de Wuhan.""Estamos pressionando a China para ter acesso total e estamos pedindo a países que levantem a questão durante suas reuniões bilaterais, [para pedir a Pequim] para cooperar"", disse Tedros Adhanom Ghebreyesus. ""Já pedimos por escrito para nos fornecerem informações e também estamos dispostos a enviar uma equipe se nos permitirem fazê-lo."
3;"A última semana de inverno, que termina no próximo sábado (23), será marcada por uma forte onda de calor que atinge parte do país, com termômetros acima de 30°C e chegando até 40°C.Segundo a Climatempo, o calor será intenso principalmente no interior de Santa Catarina, no Sudeste, Centro-Oeste e Nordeste do Paraná, no centro-sul do Pará, centro-leste do Amazonas e nos estados de Rondônia e Tocantins.Fora do normal para a época do ano, o calor extremo pode causar mal-estar, desconforto, além de outras alterações na saúde, que exige cuidados. A respiração, a pele, os rins e o coração são algumas das áreas do corpo mais afetadas pelo calor contínuo, segundo o médico Abirão Cury, da SBCM (Sociedade Brasileira de Clínica Médica).Segundo ele, o calor provoca uma dilatação dos vasos sanguíneos, o que diminui a pressão e pode levar a uma sobrecarga na circulação.
4;"O vice-presidente Geraldo Alckmin surpreendeu ao citar o mestre Miyagi, personagem de ""Karatê Kid"", em um vídeo publicado neste domingo em suas redes sociais.Na publicação, ele parabenizava os atletas de caratê de todo o Brasil que participaram do 30º Campeonato Brasileiro de Karatê Interestilos.""Lembrem-se sempre do ensinamento do mestre Miyagi, em 'Karatê Kid': 'A vida pode te derrubar, mas você decide quando é hora de levantar'."" Mais"
5;"Os economistas consultados pelo BC (Banco Central) para o Boletim Focus abaixaram nesta segunda-feira (11) a expectativa de inflação para o fim de 2023 para 4,86%, contra 4,93% no relatório divulgado na última semana. A projeção para 2024 também caiu para 3,86%.O índice de referência, IPCA (Índice Nacional de Preços ao Consumidor Amplo), saiu com alta menor do que a esperada pelo mercado, segundo os dados divulgados pelo IBGE (Instituto Brasileiro de Geografia e Estatística) na última terça-feira (12). A inflação acumulada em 12 meses até agosto está em 4,61%.Economistas corrigiram, então, as expectativas. Para 2025 e 2026 a estimativa continua sendo de inflação de 3,5% para ambos os casos. O Copom (Comitê de Política Monetária) se reunirá a partir desta terça-feira (19), para definir a taxa de juros.O centro da meta oficial para a inflação em 2023 é de 3,25% e para 2024, 2025 e 2026 é de 3,00%, sempre com margem de tolerância de 1,5 ponto percentual para mais ou menos.As projeções dos economistas consultados pelo BC para a taxa básica de juros, Selic, seguem as mesmas para os anos de análise -de 2023 a 2026.
6;"Em uma sala cheia de livros de cozinha, um texto escrito à mão na primeira página de um deles traz uma dedicatória: ""Nina, querida, como posso te agradecer?"". No final, a assinatura diz: ""com amor, Ritinha"".A edição de 2008 de ""A Conversa Chegou à Cozinha"" (ed. Ediouro, 224 págs.), com um recado da chef e apresentadora Rita Lobo, faz parte de uma coleção de cerca de 2.500 títulos que pertenceram a Nina Horta (1939-2019), cozinheira, cronista e colunista da Folha, e que a partir do dia 2 de outubro serão abertos ao público em um espaço dedicado à artista na escola de gastronomia La Fondra, Bloco D, São Paulo, na Vila Madalena.Chamado Memorial Nina Horta, também vai incluir utensílios e uma
Ln 1, Col 1 26.716 caracteres Texto sem formatação 100% Windows (CRLF) UTF-8
```

```
1.1_Segmentacao_Limpeza_v1_copy.ipynb
File Edit View Insert Runtime Tools Help

Commands + Code + Text Run all

Table of contents
Segmentação e limpeza
1 Preparação do ambiente
1.1 Tempo inicial de pro...
1.2 Funções e classes a...
1.3 Tratamento de logs
1.4 Identificando o amb...
1.5 Collaboratory
1.6 Montar uma pasta no...
1.7 Instalação do spaCy
1.8 Instalação do BERT
1.9 Instalação do tfidf
2 Parametrização
Gerais
Especificos
Nome do diretório dos ...
Define o caminho para ...
3 spaCy
3.1 Download arquivo m...
3.2 Carrega o modelo
4 Carregando BERT
4.1 Carregando o model...
4.2 Carregando o token...
5 Pré-processamento do ...
5.1 Carrega os dados br...
5.1.1 Especifica nome ...

df_dataset = pd.read_csv(DIRETORIO_LOCAL + NOME_ARQUIVO_DATASET, sep=";", encoding="UTF-8")

Corrigir o tipo de dados da lista dos documentos

Na lista
• coluna 1 - sentenças carregadas do arquivo vem como string e não como lista.

[45] ✓ Os
# Import das bibliotecas.
import ast # Biblioteca para conversão de string em lista

# Verifica se o tipo da coluna não é list e converte
df_dataset["sentenças"] = df_dataset["sentenças"].apply(lambda x: ast.literal_eval(x) if type(x)!=list else x)

logging.info("TERMINADO CORREÇÃO DOCUMENTOS: {}".format(len(df_dataset)))

INFO:root:TERMINADO CORREÇÃO DOCUMENTOS: 30.

[46] ✓ Os
df_dataset.sample(5)

id sentenças documento
9 10 [A Justiça de Mato Grosso condenou um laborató... A Justiça de Mato Grosso condenou um laboratór...
17 18 [Luan Araújo ainda se lembra do primeiro encon... Luan Araújo ainda se lembra do primeiro encont...
12 13 [Quando tinha 20 anos de idade, Randolph Nesse... Quando tinha 20 anos de idade, Randolph Nesse ...
6 6 [Em uma sala cheia de livros de cozinha, um te... Em uma sala cheia de livros de cozinha, um tex...
21 22 [O Governo do Amazonas anunciou neste domingo ... O Governo do Amazonas anunciou neste domingo (...

6 Finalização
+ Code + Text
6.1 Tempo final de processamento
```

2- Um exemplo de POS Tagging de uma sentença do texto.

<

index,id,pos_documento

15,16,"Um,aspecto,da,discussão,sobre,a,sucessão,de,Rosa,Weber,no,Supremo,Tribunal,Federal,extrapola,os,mu ndos,jurídico,e,partidário,e,realça,fraturas,mais,amplas,na,esquerda,.,DET,NOUN,ADP,NOUN,ADP,DET,NOUN,AD P,PROPN,PROPN,ADP,PROPN,PROPN,PROPN,VERB,DET,NOUN,ADJ,CCONJ,ADJ,CCONJ,VERB,NOUN,ADV,ADJ,ADP, NOUN,PUNCT,extrapola,realça,um,aspecto,de o, discussão,sobre,o,sucessão,de,Rosa,Weber,em o,Supremo,Tribunal,Federal,extrapolar,o,mundo,jurídico,e,partidário,e,realçar,fratura,mais,amplo,em o,esquerda,.,Lula,(,PT,),tem,sido,pressionado,por,grupos,da,sociedade,civil,a,indicar,uma,mulher,negra,para,a,c orte,—,numa,campanha,que,envolve,hashtags,,,um,curta-metragem,e,ações,fora,do,país,.,PROPN,PUNCT,PROPN,PUNCT,AUX,AUX,VERB,ADP,NOUN,ADP,NOUN,ADJ,SCONJ,VERB,DET,NOUN,ADJ,ADP,DET,NOUN,PUNCT,ADP,NOUN,PRON,VERB,NOUN,PUNCT,DET,NOUN,CCONJ,NOUN,A DV,ADP,NOUN,PUNCT,tem,sido,pressionado,indicar,envolve,Lula,(,PT,),ter,ser,pressionar,por,grupo,de o,sociedade,civil,a,indicar,um,mulher,negro,para,o,corte,—,em um,campanha,que,envolver,hashtags,,,um,curta-metragem,e,ação,fora,de o,país,.,O,tema,virou,ponto,de,tensão,até,entre,grupos,que,apoiam,o,governo.,DET,NOUN,VERB,NOUN,ADP,NO UN,ADP,ADP,NOUN,PRON,VERB,DET,NOUN,PUNCT,virou,apoiam,o,tema,virar,ponto,de,tensão,até,entre,grupo, que,apoiar,o,governo.,De,um,lado,,,os,que,enfatizam,a,importância,de,ampliar,a,diversidade,no,Supremo.,ADP ,DET,NOUN,PUNCT,PRON,PRON,VERB,DET,NOUN,SCONJ,VERB,DET,NOUN,ADP,PROPN,PUNCT,enfatizam,ampliar ,de,um,lado,,,o,que,enfatizar,o,importância,de,ampliar,o,diversidade,em o,Supremo.,De,outro,,,quem,defende,que,Lula,priorize,a,escolha,de,alguém,de,confiança,—,como,o,ex-advogado,dele,Cristiano,Zanin,,,nomeado,em,junho.,ADP,PRON,PUNCT,PRON,VERB,SCONJ,PROPN,VERB,DET,NOUN,ADP,PRON,ADP,NOUN,PUNCT,ADP,DET,NOUN,PRON,PROPN,PROPN,PUNCT,VERB,ADP,NOUN,PUNCT,defen de,priorize,nomeado,de,outro,,,quem,defender,que,Lula,priorizar,o,escolha,de,alguém,de,confiança,—, como,o,ex-advogado,de ele,Cristiano,Zanin,,,nomear,em,junho.,O,embate,reflete,uma,divisão,na,esquerda,que,não,é,nova,nem,exclusiv a,do,Brasil,,,mas,que,voltou,a,aflorar,.,DET,NOUN,VERB,DET,NOUN,ADP,NOUN,PRON,ADV,AUX,ADJ,CCONJ,ADJ, ADP,PROPN,PUNCT,CCONJ,PRON,VERB,SCONJ,VERB,PUNCT,reflete,voltou,aflorar,o,embate,refletir,um,divisão,e m o,esquerda,que,não,ser,novo,nem,exclusivo,de o,Brasil,,,mas,que,voltar,a,aflorar,."

3- Um exemplo de NER de uma sentença do texto.

The screenshot shows a Jupyter Notebook titled '1_3_NER_spacy_v1_copy.ipynb'. The left sidebar contains a 'Table of contents' with sections 4.1 to 5.1. The main area displays three code cells. Cell [42] prints the entities from a document: 'Luva de Pedreiro 26 42 MISC', 'Távila Gomes 118 130 PER', 'Távila 285 291 PER', 'Luva 430 434 LOC', and 'Iran Ferreira 578 591 PER'. Cell [43] shows the list of entities as a list of tuples: [(Luva de Pedreiro, 'MISC'), (Távila Gomes, 'PER'), (Távila, 'PER'), (Luva, 'LOC'), (Iran Ferreira, 'PER')]. Cell [44] shows the text with entities highlighted and labeled: 'Na tarde de domingo (17), Luva de Pedreiro MISC abriu uma live e sugeriu que o melhor seria pagar pensão à atual namorada. Távila Gomes PER, grávida do primeiro filho dele. "Sou inamorável", disse ele, deixando seus seguidores perplexos com um suposto fim precoce do romance. Porém, mais tarde, Távila PER desmentiu que ambos tenham encerrado o vínculo. Em outra live, ambos ironizaram perguntas sobre o suposto fim do relacionamento. Conforme Luva LOC, as frases horas antes teriam sido "resenha", ou seja, brincadeira. "Não pode falar mais nada. Tudo o que eu faço, eu estou errado." Em agosto, Iran Ferreira PER anunciou que será pai.'

[(Luva de Pedreiro, 'MISC'),

(Távila Gomes, 'PER'),



(Távila, 'PER'),

(Luva, 'LOC'),


(Iran Ferreira, 'PER')]

Na tarde de domingo (17), Luva de Pedreiro MISC abriu uma live e sugeriu que o melhor seria pagar pensão à atual namorada, Távila Gomes PER , grávida do primeiro filho dele. "Sou inamorável", disse ele, deixando seus seguidores perplexos com um suposto fim precoce do romance. Porém, mais tarde, Távila PER desmentiu que ambos tenham encerrado o vínculo. Em outra live, ambos ironizaram perguntas sobre o suposto fim do relacionamento. Conforme Luva LOC , as frases horas antes teriam sido "resenha", ou seja, brincadeira. "Não pode falar mais nada. Tudo o que eu faço, eu estou errado." Em agosto, Iran Ferreira PER anunciou que será pai.


4- Os gráficos e tabelas da análise de dados do texto gerados pelos notebooks.







Quantidade de documentos por quantidade de palavras







Quantidade de documentos por quantidade de tokens















Tamanhos dos documentos tokenizados classificados




Quantidade de sentenças de documentos por quantidade de palavras







Quantidade de sentenças de documentos por quantidade de locuções verbais



Quantidade de sentenças de documentos por quantidade de verbos



Quantidade de sentenças por documentos por quantidade de verbos e aux



Quantidade de sentenças de documentos por quantidade de substantivos

